

Obsah

Úvod	2
I Optimalizace	3
1 Základní geometrické pojmy	4
1.1 Přímký a úsečky	4
1.2 Afinity prostory	4
1.3 Konvexní množiny	5
1.4 Kužely	5
1.5 Nadroviny a poloprostory	6
1.6 Polyedry a polytopy	8
2 Konvexní optimalizace	10
2.1 Obecná podmíněná úloha	10
2.2 Konvexní podmíněná úloha	11
2.3 Lagrangeova dualita	11
2.3.1 Dolní odhad na x^*	11
2.3.2 Duální úloha	12
2.3.3 Slabá dualita	12
2.3.4 Silná dualita a Slaterova podmínka	12
3 Lineární programování	14
3.1 Primární úloha	14
3.2 Dualita	15
3.3 Komplementární skluzovost	17
4 Semidefinitní programování	19
4.1 Vsuvka z lineární algebry	19
4.2 Primární úloha	22
4.3 Dualita	24

<i>OBSAH</i>	1
5 Kombinatorická optimalizace	26
5.1 Celočíslné lineární programování	26
5.2 Celočíslné semidefinitní programování	26
II Kombinatorické úlohy	27
6 Shannonova kapacita	28
6.1 $\Theta(C_5) = \sqrt{5}$	29
6.2 Další vlastnosti $\vartheta(G)$	31
6.3 Semidefinitní program pro $\vartheta(G)$	31
7 Problém maximálního řezu	32
7.1 Kvadratické programování	32
7.2 Relaxace a vektorové programování	32
8 Problém obchodního cestujícího	33
Závěr	34

Úvod

Část I

Optimalizace

Kapitola 1

Základní geometrické pojmy

1.1 Přímký a úsečky

Mějme dva body $x_1, x_2 \in \mathbb{R}^n$ takové, že $x_1 \neq x_2$ a parametr $\theta \in \mathbb{R}$. Potom výraz

$$y = \theta x_1 + (1 - \theta)x_2 \quad (1.1)$$

popisuje **přímku** procházející body x_1 a x_2 . Pro $\theta = 0$ dostáváme bod x_2 a pro $\theta = 1$ bod x_1 . Omezíme-li θ na interval $\langle 0, 1 \rangle$, dostaneme **úsečku** s koncovými body x_1 a x_2 . Výraz 1.1 lze přepsat do tvaru

$$y = x_2 + \theta(x_1 - x_2),$$

který můžeme interpretovat jako součet počátečního bodu x_2 a nějakého násobku směrového vektoru $x_1 - x_2$.

1.2 Afinní prostory

Říkáme, že $C \subseteq \mathbb{R}^n$ je **afinní prostor**, jestliže přímka procházející libovolnými dvěma různými body z C leží v C . Tedy C obsahuje lineární kombinace libovolných dvou bodů z C , jestliže součet koeficientů lineární kombinace je roven jedné. To lze zobecnit i pro více než dva body. Lineární kombinace $\theta_1 x_1 + \dots + \theta_k x_k$ bodů x_1, \dots, x_k taková, že $\theta_1 + \dots + \theta_k = 1$, se nazývá **afinní kombinace** bodů x_1, \dots, x_k . Indukcí z definice afinního prostoru lze snadno ukázat, že pokud C je afinní množina, $x_1, \dots, x_k \in C$ a $\theta_1 + \dots + \theta_k = 1$, potom bod $\theta_1 x_1 + \dots + \theta_k x_k \in C$.

Nechť C je afinní prostor a $x_0 \in C$, potom množina

$$V = C - x_0 = \{x - x_0 \mid x \in C\}$$

je **vektorový prostor**, tj. množina, která je uzavřená na sčítání a násobení skalárem.

Afinní prostor C lze vyjádřit jako

$$C = V + x_0 = \{v + x_0 \mid v \in V\},$$

kde V je vektorový prostor a x_0 je počátek. Poznamenejme, že vektorový prostor V asociovaný s afinním prostorem C nezávisí na volbě počátku x_0 .

Dimenze afinního prostoru $C = V + x_0$ je definována jako dimenze vektorového prostoru $V = C - x_0$, kde x_0 je libovolný prvek z C . Množina všech afinních kombinací bodů množiny $C \subseteq \mathbb{R}^n$ se nazývá **afinní obal** množiny C . Afinní obal množiny C budeme značit

$$\mathbf{aff} C = \{\theta_1 x_1 + \cdots + \theta_k x_k \mid x_1, \dots, x_k \in C, \theta_1 + \cdots + \theta_k = 1\}.$$

Afinní obal je nejmenší afinní prostor, který obsahuje množinu C . Tedy, jestliže S je afinní prostor takový, že $C \subseteq S$, potom $\mathbf{aff} C \subseteq S$.

1.3 Konvexní množiny


Říkáme, že množina C je **konvexní**, jestliže úsečka mezi libovolnými dvěma body z C leží také v C . Jinak řečeno, jestliže pro libovolné dva body $x_1, x_2 \in C$ a libovolné $\theta \in \langle 0, 1 \rangle$ platí, že $\theta x_1 + (1 - \theta)x_2 \in C$. Poznamenejme, že každý afinní prostor je zároveň konvexní množinou. Podobně jako afinní kombinaci definujeme **konvexní kombinaci** bodů x_1, \dots, x_k jako $\theta_1 x_1 + \cdots + \theta_k x_k$, kde $\theta_1 + \cdots + \theta_k = 1, \theta_i \geq 0$ pro $i = 1, \dots, k$. **Konvexní obal** množiny C je množina všech konvexních kombinací bodů z množiny C , značíme

$$\mathbf{conv} C = \{\theta_1 x_1 + \cdots + \theta_k x_k \mid x_i \in C, \theta_i \geq 0, i = 1, \dots, k, \theta_1 + \cdots + \theta_k = 1\}.$$

Analogicky, konvexní obal množiny C je nejmenší konvexní množina, která obsahuje množinu C . Pro představu viz obrázek 1.1.

1.4 Kužely

Množina C se nazývá **kužel**, jestliže pro každé $x \in C$ a $\theta \geq 0$ platí, že $\theta x \in C$. Je-li C navíc konvexní, pak se C nazývá **konvexní kužel**. Tedy C je konvexní kužel, jestliže pro libovolné $x_1, x_2 \in C$ a $\theta_1, \theta_2 \geq 0$ platí, že $\theta_1 x_1 + \theta_2 x_2 \in C$. Říkáme, že bod ve tvaru $\theta_1 x_1 + \cdots + \theta_k x_k$, kde $\theta_1, \dots, \theta_k \geq 0$ je **kuželovou kombinací** bodů x_1, \dots, x_k . Dále, pokud x_i leží v konvexním kuželu množiny C , potom libovolná kuželová kombinace bodu x_i leží rovněž

(a) Množina bodů C (b) $\text{conv } C$

Obrázek 1.1: Konvexní obal množiny

v konvexním kuželu množiny C . Platí, že množina C je konvexní kužel právě tehdy, když C obsahuje všechny kuželové kombinace svých bodů. **Kuželový obal** množiny C je množina, která obsahuje všechny kuželové kombinace množiny C , tj.

$$\text{cone } C = \{\theta_1 x_1 + \cdots + \theta_k x_k \mid x_i \in C, \theta_i \geq 0, i = 1, \dots, k\}.$$

Kuželový obal množiny C je zároveň nejmenší konvexní kužel, který obsahuje množinu C . Pro představu viz obrázek 1.2.


1.5 Nadroviny a poloprostory

Nadrovina je množina ve tvaru

$$\{x \mid a^T x = b\},$$

kde $a \in \mathbb{R}^n$, $a \neq 0$ a $b \in \mathbb{R}$. Analyticky se na nadrovinu koukáme jako na množinu všech řešení netriviální lineární rovnice. Geometricky zase jako na množinu všech bodů takových, že mají konstantní skalární součin s normálovým vektorem a . Konstanta b značí posunutí nadroviny od počátku. Nadrovinu také můžeme vyjádřit jako

$$\{x \mid a^T(x - x_0) = 0\} = x_0 + \{v \mid a^T v = 0\},$$

(a) Množina bodů C (b) **cone** C

Obrázek 1.2: Kuželový obal množiny

kde x_0 je libovolný bod této nadroviny a $\{v \mid a^T v = 0\}$ je množina všech vektorů, které jsou kolmé k normálovému vektoru a . Nadrovina je tedy množina, která obsahuje bod x_0 a libovolný bod ve tvaru $x_0 + v$, kde v je vektor, který je kolmý k normálovému vektoru a . Pro ilustraci v \mathbb{R}^2 viz obrázek 1.3a.

Nadrovina dělí \mathbb{R}^n na dva poloprostory. Množina


$$\{x \mid a^T x \leq b\}, \text{ resp. } \{x \mid a^T x < b\},$$

kde $a \neq 0$ se nazývá (uzavřený) **poloprostor**, resp. **otevřený poloprostor**. Je to tedy množina všech řešení netriviální lineární nerovnice. Podobně jako


nadrovinu, můžeme poloprostor vyjádřit ve tvaru

$$\{x \mid a^T(x - x_0) \leq 0\}, \text{ resp. } \{x \mid a^T(x - x_0) < 0\},$$

kde $a \neq 0$ a x_0 je libovolný bod z nadroviny $\{x \mid a^T x = b\}$. Poloprostor tedy obsahuje bod x_0 a libovolný bod $x_0 + v$, kde v je vektor, který s vnějším normálovým vektorem svírá tupý nebo pravý úhel. Tato interpretace je v \mathbb{R}^2 ilustrována na obrázku 1.3b. Ještě poznamenejme, že poloprostory jsou konvexní množiny, ale samozřejmě nejsou afinní.



(a) Nadrovina



(b) Poloprostor

Obrázek 1.3: Nadrovina a poloprostor v \mathbb{R}^2 .

1.6 Polyedry a polytopy

Polytopy jsou zobecněním konvexních mnohoúhelníků v rovině do více dimenzí. Polytop v \mathbb{R}^3 je konvexní množina, která je ohraničena konečně mnoha konvexními mnohoúhelníky (příkladem polytopů v \mathbb{R}^3 jsou např. Platónská tělesa). Na takovou množinu je možné nahlížet dvěma způsoby. **H-polyedr** je průnik konečně mnoha uzavřených poloprostorů v \mathbb{R}^n , kde **H-polytop** je omezený H-polyedr. **V-polytop** je konvexní obal konečně mnoha bodů v \mathbb{R}^n . Následující věta říká, že H-polytop a V-polytop jsou matematicky ekvivalentní množiny.

Věta 1. *Každý V-polytop je H-polytop. Každý H-polytop je V-polytop.*

Poznamenejme, že V-polytop a H-polytop jsou sice ekvivalentní množiny, ale z algoritmického hlediska je velký rozdíl, zda pracujeme s bodovou množinou, nebo s uzavřenými poloprostory. Pro ilustraci: mějme lineární funkci, kterou chceme minimalizovat na daném polytopu. Pro V-polytop se jedná o triviální problém, protože stačí pro každý bod z množiny V určit hodnotu dané funkce a vybrat minimum. Na druhou stranu pro H-polytop se jedná o netriviální problém, kterým se zabývá lineární programování. Dále budeme mluvit jen o **polyedrech** a **polytopech**.

Důležitý fakt, že každý polyedr je konečně generovaný, říká Minkowského-Weylova věta.

Věta 2 (Minkowski-Weyl). $P \subseteq \mathbb{R}^n$. Potom $P = \mathbf{conv}(u_1, \dots, u_r) + \mathbf{cone}(v_1, \dots, v_s)$, kde u_i, v_i jsou extrémní vrcholy P právě tehdy, když $P = \{x \in \mathbb{R}^n \mid Ax \leq b\}$, $A \in \mathbb{R}^{m \times n}$, $b \in \mathbb{R}^m$.

Kapitola 2

Konvexní optimalizace

2.1 Obecná podmíněná úloha

$$\begin{aligned} \min \quad & f(x) \\ & g_i(x) \leq 0, i = 1, \dots, m \\ & h_i(x) = 0, i = 1, \dots, p \end{aligned} \tag{2.1}$$

Hledáme $x \in \mathbb{R}^n$, které minimalizuje $f(x)$, vzhledem k omezením $g_i(x)$ a $h_i(x)$. Proměnné x říkáme **optimalizační proměnná**, funkci $f(x)$ říkáme **cenová** nebo **účelová funkce**. Výrazy $g_i(x) \leq 0$ jsou **omezení typu nerovnosti** a $h_i(x) = 0$ jsou **omezení typu rovnosti**. Pokud $m = p = 0$ problém 2.1 je **neomezený**, jinak je **omezený**.

Definiční obor \mathcal{D} úlohy 2.1 je

$$\mathcal{D} = \bigcap_{i=1}^m \text{dom } g_i \cap \bigcap_{i=1}^p \text{dom } h_i.$$

Říkáme, že bod $x \in \mathcal{D}$ je **přípustný**, jestliže splňuje všechna omezení $g_i(x) \leq 0$ a $h_i(x) = 0$. Úloha 2.1 je **přípustná**, jestliže existuje alespoň jeden bod $x \in \mathcal{D}$, který je přípustný. Množina všech přípustných bodů $x \in \mathcal{D}$ se nazývá **přípustná množina**.

Optimální hodnota x^* úlohy 2.1 je definována jako

$$x^* = \{f(x) \mid g_i(x) \leq 0, i = 1, \dots, m, h_i(x) = 0, i = 1, \dots, p\}.$$

2.2 Konvexní podmíněná úloha

$$\begin{aligned} \min \quad & f(x) \\ & g_i(x) \leq 0, i = 1, \dots, m \\ & a_i^T x = b_i, i = 1, \dots, p \end{aligned} \quad (2.2)$$

Oproti obecné úloze 2.1 jsou funkce $f(x)$, $g_i(x)$ konvexní a funkce $h_i(x) = a_i^T x - b_i$ jsou afinní. Přípustná množina takové úlohy je konvexní množinou.

2.3 Lagrangeova dualita

Mějme úlohu 2.1 s $\mathcal{D} \neq \emptyset$. Zobrazení $L : \mathbb{R}^n \times \mathbb{R}^m \times \mathbb{R}^p \rightarrow \mathbb{R}$ takové, že

$$L(x, \lambda, \mu) = f(x) + \sum_{i=1}^m \lambda_i g_i(x) + \sum_{i=1}^p \mu_i h_i(x) \quad (2.3)$$

se nazývá **Lagrangeova funkce**. Definiční obor $\text{dom } L = \mathcal{D} \times \mathbb{R}^m \times \mathbb{R}^p$. Vektory λ a μ nazýváme **duální proměnné** a prvkům těchto vektorů říkáme **Lagrangeovy multiplikátory**. Dále definujeme **duální funkci** $d : \mathbb{R}^m \times \mathbb{R}^p \rightarrow \mathbb{R}$ jako infimum Lagrangeovy funkce L přes všechna $x \in \mathcal{D}$. Tedy

$$d(\lambda, \mu) = \inf_{x \in \mathcal{D}} L(x, \lambda, \mu) = \inf_{x \in \mathcal{D}} \left(f(x) + \sum_{i=1}^m \lambda_i g_i(x) + \sum_{i=1}^p \mu_i h_i(x) \right). \quad (2.4)$$

Poznamenejme, že duální funkce je konkávní bez ohledu na to, zda je úloha konvexní a je-li L zdola neomezená v proměnné x , potom duální funkce nabývá hodnoty $-\infty$.

2.3.1 Dolní odhad na x^*

Nechť \tilde{x} je přípustný bod. Pro $\lambda \geq 0$ je

$$\sum_{i=1}^m \lambda_i g_i(\tilde{x}) + \sum_{i=1}^p \mu_i h_i(\tilde{x}) \leq 0.$$

Potom pro Lagrangeovu funkci můžeme psát

$$L(\tilde{x}, \lambda, \mu) = f(\tilde{x}) + \sum_{i=1}^m \lambda_i g_i(\tilde{x}) + \sum_{i=1}^p \mu_i h_i(\tilde{x}) \leq f(\tilde{x}).$$

A tedy pro duální funkci platí

$$d(\lambda, \mu) = \inf_{x \in \mathcal{D}} L(x, \lambda, \mu) \leq L(\tilde{x}, \lambda, \mu) \leq f(\tilde{x}).$$

2.3.2 Duální úloha

V části 2.3.1 jsme si ukázali, že duální funkce dává dolní odhad na optimální hodnotu x^* úlohy 2.1. Stále jsme si ale neřekli, jaký je nejlepší dolní odhad, který pomocí duální funkce jsme schopni dostat. To nás dostává k následující optimalizační úloze.

$$\begin{aligned} \max d(\lambda, \mu) \\ \lambda \geq 0 \end{aligned} \tag{2.5}$$

Úloze 2.5 se říká **Lagrangeova duální úloha** příslušná k úloze 2.1, kterou nazýváme **primární úlohou**.

2.3.3 Slabá dualita

Optimální řešení Lagrangeovy duální úlohy označíme d^* , které je už z definice nejlepší dolní odhad na optimální řešení primární úlohy p^* . Tato nerovnost platí i pokud primární úloha není konvexní. Této nerovnosti říkáme **slabá dualita**. Rozdíl optimálních řešení $p^* - d^*$ označujeme jako **optimální dualitní rozdíl** primární úlohy. Poznamenejme, že optimální dualitní rozdíl je vždy nezáporný.

2.3.4 Silná dualita a Slaterova podmínka

Pokud je optimální dualitní rozdíl $p^* - d^* = 0$, pak říkáme, že platí silná dualita. Silná dualita obecně neplatí, ale pro primární úlohu, která splňuje nějaké další podmínky to možné je. Těmto podmínkám se říká **podmínky kvalifikace omezení**. Jednou takovou je **Slaterova podmínka**:

$$\exists x \in \text{relint } \mathcal{D} : f_i(x) < 0, i = 1, \dots, m, Ax = b.$$

Bodu $x \in \mathcal{D}$, který splňuje Slaterovu podmínku, říkáme, že je **striktně přípustný**, protože omezení typu nerovnosti jsou ostré. Pokud jsou některé funkce f_i afinní, můžeme Slaterovu podmínku modifikovat. Nechť tedy $f_1, \dots, f_k, k \leq m$, jsou afinní funkce. Potom **modifikovaná Slaterova podmínka** má tvar:

$$\exists x \in \text{relint } \mathcal{D} : f_i(x) \leq 0, i = 1, \dots, k, f_i(x) < 0, i = k + 1, \dots, m, Ax = b.$$

Pro úlohu 2.2 platí následující věta.

Věta 3 (Slaterova). *Nechť primární úloha je konvexní a platí (modifikovaná) Slaterova podmínka, potom $p^* = d^*$.*

TODO

Použití duální úlohy: obecnou primární úlohu je těžké vyřešit, ale duální úloha je vždy konvexní, tak vyřeším tu a mám alespoň dolní odhad na primární úlohu

Kapitola 3

Lineární programování

3.1 Primární úloha

Úlohou lineárního programování rozumíme minimalizaci nebo maximalizaci lineární **účelové funkce** vzhledem k lineárním **omezením**, kde tato omezení jsou dána soustavou lineární rovnic a nerovnic. Úlohu lineárního programování lze formulovat v několika ekvivalentních tvarech, které se liší zadáním omezení. Úloha v **kanonickém tvaru** má svá omezení dána soustavou lineárních nerovnic $Ax \leq b$. Tedy:


$$\max \{c^T x \mid Ax \leq b, x \geq 0\}, \quad (\text{LP-P})$$

kde $A \in \mathbb{R}^{m \times n}$, $b \in \mathbb{R}^n$, $x \in \mathbb{R}^n$ a $c \in \mathbb{R}^n$. **Přípustná množina řešení** je průnikem poloprostorů, které jsou definovány soustavou nerovnic $Ax \leq b$ a **nezáporného ortantu**, tj. množiny $\{x \in \mathbb{R}^n \mid x_i \geq 0, i = 1, \dots, n\}$. Obě tyto množiny jsou konvexní a tedy i jejich průnik je rovněž konvexní množina. Dále, protože přípustnou množinu máme popsanou soustavou konečně mnoha lineárních nerovnic, geometricky se na úlohu LP-P můžeme koukat jako na maximalizaci lineární funkce přes polyedr, který je definován touto soustavou.

Příklad. Mějme následující úlohu:

$$\begin{aligned} \max x_1 + x_2 \\ -x_1 + 3x_2 &\leq 4 \\ 4x_1 - x_2 &\leq 6 \\ x &\geq 0. \end{aligned} \quad (\text{P1})$$

Přípustná množina řešení je zobrazena na obrázku 3.1. Řešením úlohy je vektor $x^* = (2, 2)$ s cenou 4. Implementace v softwaru MOSEK: <https://github.com/c0n73x7/D1PL0MK4/blob/master/mosek/ex1.py>.



Obrázek 3.1: Přípustná množina řešení k úloze P1.

3.2 Dualita

Pomocí Lagrangeovy duality odvodíme duální úlohu k primární úloze LP-P. Máme tedy optimalizační úlohu

$$\min \{ -c^T x \mid Ax \leq b, x \geq 0 \}.$$

Pro ní vytvoříme Lagrangeovu funkci

$$\begin{aligned} L(x, \lambda) &= -c^T x + \lambda^T (Ax - b) - \lambda^T x \\ &= -b^T \lambda + (A^T \lambda - c - \lambda)^T x. \end{aligned}$$

Z Lagrangeovy funkce přejdeme k duální funkci

$$\begin{aligned} d(\lambda) &= \inf_x L(x, \lambda) \\ &= \inf_x -b^T \lambda + (A^T \lambda - c - \lambda)^T x \\ &= \begin{cases} -b^T \lambda & \text{pokud } A^T \lambda - c - \lambda = 0, \\ -\infty & \text{jinak.} \end{cases} \end{aligned}$$

Tu nakonec použijeme v duální úloze:

$$\max \{ -b^T \lambda \mid A^T \lambda - c - \lambda = 0 \}$$

$$\max \{ -b^T \lambda \mid A^T \lambda \geq c, \lambda \geq 0 \}$$


$$\min \{b^T \lambda \mid A^T \lambda \geq c, \lambda \geq 0\} \quad (\text{LP-D})$$

Dostáváme tedy duální úlohu LP-D k primární úloze LP-P.

Příklad. Duální úloha k úloze P1 je ve tvaru:

$$\begin{aligned} \min & 4y_1 + 6y_2 \\ & -y_1 + 4y_2 \geq 1 \\ & 3y_1 - y_2 \geq 1 \\ & y \geq 0. \end{aligned} \quad (\text{P2})$$

Přípustná množina řešení je zobrazena na obrázku 3.2. Řešením úlohy je vektor $y^* \approx (0.4546, 0.3636)$ s cenou 4. Implementace v softwaru MOSEK: <https://github.com/c0n73x7/D1PL0MK4/blob/master/mosek/ex2.py>.



Obrázek 3.2: Přípustná množina řešení k úloze P2.

Všimněme si, že v příkladech P1 a P2 mají řešení x^* i y^* stejnou cenu. To není náhoda a tento fakt je obsahem silné věty o dualitě lineárního programování, kterou dokázala skupina kolem Alberta W. Tuckera v roce 1948. Začneme slabou větou o dualitě lineárního programování.

Věta 4 (Slabá o dualitě). *Nechť \tilde{x} je přípustné řešení LP-P a \tilde{y} je přípustné řešení LP-D. Potom $c^T \tilde{x} \leq b^T \tilde{y}$.*

Tedy každé přípustné řešení \tilde{y} duální úlohy LP-D nám dává horní odhad na maximum účelové funkce primární úlohy LP-P. Graficky můžeme slabou

větu o dualitě interpretovat jako na obrázku 3.3. Zatím tedy nevíme, zda vždy existují přípustná (optimální) řešení x^* pro úlohu LP-P a y^* pro úlohu LP-D, pro která platí $c^T x^* = b^T y^*$. Kladnou odpověď dostaneme z již zmíněné silné věty od dualitě.



Obrázek 3.3: Slabá věta o dualitě.

Věta 5 (Silná o dualitě). *Jestliže úlohy LP-P a LP-D mají přípustná řešení. Potom*

$$\max \{c^T x \mid Ax \leq b, x \geq 0\} = \min \{b^T y \mid A^T y \geq c, y \geq 0\}.$$

Se znalostí silné věty o dualitě můžeme obrázek 3.3 upravit na obrázek 3.4.



Obrázek 3.4: Ceny přípustných řešení primární a příslušné duální úlohy.

3.3 Komplementární skluzovost

Pro odvození tzv. podmínky komplementární skluzovosti nejprve převedeme úlohy LP-P a LP-D do jiných tvarů. V primární úloze povolíme $x \in \mathbb{R}^n$. Tedy primární úloha je ve tvaru:

$$\max \{c^T x \mid Ax \leq b\}. \quad (\text{LP-P2})$$

A příslušná duální úloha je ve tvaru:

$$\min \{b^T y \mid A^T y = c, y \geq 0\}. \quad (\text{LP-D2})$$

Nechť \tilde{x} je přípustné řešení a x^* je optimální řešení úlohy LP-P2, \tilde{y} je přípustné řešení a y^* je optimální řešení úlohy LP-D2. **Dualitní rozdíl** \tilde{x} a \tilde{y} je číslo $b^T \tilde{y} - c^T \tilde{x} \geq 0$. Ze silné věty o dualitě samozřejmě plyne, že pro optimální řešení x^* a y^* je dualitní rozdíl roven 0. Vyjdeme z dualitního rozdílu optimálních řešení:

$$b^T y^* - c^T x^* = y^{*T} b - y^{*T} A x^* = y^{*T} (b - A x^*) = 0.$$

Poslední rovnost přepíšeme maticově:

$$[y_1^*, \dots, y_m^*] \left(\begin{bmatrix} b_1 \\ \vdots \\ b_m \end{bmatrix} - \begin{bmatrix} a_{11} & \dots & a_{1n} \\ \vdots & & \vdots \\ a_{m1} & \dots & a_{mn} \end{bmatrix} \begin{bmatrix} x_1^* \\ \vdots \\ x_n^* \end{bmatrix} \right) = \begin{bmatrix} 0 \\ \vdots \\ 0 \end{bmatrix}.$$

Dostáváme tedy soustavu rovnic $y_i^* (b_i - a_{i\cdot} x^*) = 0$, kde $i = 1, \dots, m$. Tedy buď $y_i^* = 0$ nebo $b_i - a_{i\cdot} x^* = 0$. **Podmínka komplementární skluzovosti** je splněna, jestliže pro přípustná řešení \tilde{x}, \tilde{y} platí buď $\tilde{y}_i = 0$ nebo $b_i - a_{i\cdot} \tilde{x} = 0$, $i = 1, \dots, m$. Pokud nastane $b_i - a_{i\cdot} \tilde{x} = 0$, potom říkáme, že **vazba** $a_{i\cdot} \tilde{x} \leq b_i$ **je aktivní**.

Věta 6. *Nechť \tilde{x} je přípustné řešení LP-P2 a \tilde{y} je přípustné řešení LP-D2. Potom \tilde{x}, \tilde{y} jsou optimální právě tehdy, když platí podmínka komplementární skluzovosti.*

Kapitola 4

Semidefinitní programování

Na semidefinitní programování se můžeme koukat jako na zobecnění lineárního programování, kde proměnné jsou symetrické matice. Jedná se tedy o optimalizaci lineární funkce vzhledem k tzv. lineárním maticovým nerovnostem.

4.1 Vsuvka z lineární algebry

Pozitivně definitní matice

Pracujeme s reálnými symetrickými maticemi $S = S^T$. Ty mají všechna vlastní čísla reálná a některé z nich mají zajímavou vlastnost, že všechna jejich vlastní čísla jsou kladná. Takovým maticím říkáme, že jsou pozitivně definitní. Alternativní definicí je, že matice S je pozitivně definitní, jestliže $x^T S x > 0$ pro všechny nenulové vektory x .

Příklad.

$$x^T S x = \begin{bmatrix} x_1 & x_2 \end{bmatrix} \begin{bmatrix} 2 & 4 \\ 4 & 9 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = 2x_1^2 + 8x_1x_2 + 9x_2^2$$

Je pro všechny x nenulové $x^T S x > 0$? Ano, protože můžeme výraz přepsat na součet čtverců:

$$x^T S x = 2x_1^2 + 8x_1x_2 + 9x_2^2 = 2(x_1 + 2x_2)^2 + x_2^2.$$

TODO: obrázek kyblíčku

Ukážeme si několik kritérií, jak otestovat pozitivní definitnost dané matice.

Věta 7. $S = S^T$ je pozitivně definitní, jestliže lze napsat jako $S = A^T A$ pro nějakou matici A , která má lineárně nezávislé sloupcečky.

Důkaz.

$$x^T S x = x^T A^T A x = (Ax)^T (Ax) = \|Ax\|^2 \geq 0 \quad (4.1)$$

$\|Ax\|^2 > 0$, jestliže sloupčky matice A jsou lineárně nezávislé \square

Příklad.

$$S = \begin{bmatrix} 2 & 3 & 4 \\ 3 & 5 & 7 \\ 4 & 7 & 10 \end{bmatrix} = \begin{bmatrix} 1 & 1 \\ 1 & 2 \\ 1 & 3 \end{bmatrix} \begin{bmatrix} 1 & 1 & 1 \\ 1 & 2 & 3 \end{bmatrix} = A A^T$$

A má lineárně závislé sloupčky, tj. S není pozitivně definitní

Dalším testem je tzv. Sylvesterovo kritérium.

Věta 8. $S = S^T$ je pozitivně definitní, jestliže všechny hlavní minory S jsou kladné.

Příklad.

$$S = \begin{bmatrix} 3 & 4 \\ 4 & 6 \end{bmatrix}, D_1 = 3, D_2 = 3 \cdot 6 - 4 \cdot 4 = 2$$

hlavní minory $D_1, D_2 > 0$; matice S je pozitivně definitní

A poslední, které si uvedeme souvisí s Gaussovou eliminací.

Věta 9. $S = S^T$ je pozitivně definitní, jestliže jsou všechny pivoty při Gaussově eliminaci kladné.

Příklad.

$$S = \begin{bmatrix} 3 & 4 \\ 4 & 6 \end{bmatrix} \sim \begin{bmatrix} 3 & 4 \\ 0 & \frac{2}{3} \end{bmatrix}, p_1 = 3, p_2 = \frac{2}{3}$$

pivoty $p_1, p_2 > 0$; matice S je pozitivně definitní

Pozitivně semidefinitní matice

Pro pozitivní semidefinitnost modifikujeme předcházejí definice a tvrzení pro pozitivně definitní matice následovně:

1. $S = S^T$ je pozitivně semidefinitní, jestliže všechna její čísla jsou nezáporná.
2. $S = S^T$ je pozitivně semidefinitní, jestliže $x^T S x \geq 0$ pro všechny nenulové vektory x .
3. $S = S^T$ je pozitivně semidefinitní, jestliže lze napsat jako $S = A^T A$ pro nějakou matici A .
4. $S = S^T$ je pozitivně semidefinitní, jestliže všechny hlavní minory S jsou nezáporné.
5. $S = S^T$ je pozitivně semidefinitní, jestliže jsou všechny pivoty při eliminaci nezáporné.

Pozitivně semidefinitní kužel

Množinu všech symetrických matic značíme S^n , množinu všech pozitivně semidefinitních matic značíme S_+^n a množinu všech pozitivně definitních matic značíme S_{++}^n .

Lemma 1. *Množina S_+^n je uzavřená*

Důkaz. TODO □

Lemma 2. *Množina S_+^n tvoří konvexní kužel.*

Důkaz. $\Theta_1, \Theta_2 \geq 0, A, B \in S_+^n$

$$x^T (\Theta_1 A + \Theta_2 B) x = x^T \Theta_1 A x + x^T \Theta_2 B x \geq 0.$$

□

Lemma 3. *Kužel S_+^n je pointed.*

Důkaz. TODO □

Lemma 4. *Kužel S_+^n je samoduální.*

Důkaz. TODO □

Shrneme předchozí lemmata do následující věty.

Věta 10. *Množina S_+^n tvoří konvexní, pointed a uzavřený kužel, který je samoduální.*

Říkáme, že S_+^n je **pozitivně semidefinitní kužel**.

Spektraedry

Definujeme tzv. **Löwnerovo částečné uspořádání**:

$$A \succeq B \iff A - B \in S_+^n,$$

tj. matice $A - B$ je pozitivně semidefinitní. **Lineární maticová nerovnost** (LMI) je ve tvaru

$$A_0 + \sum_{i=1}^n A_i x_i \succeq 0,$$

kde $A_i \in S^n$.

Množina $S \subset \mathbb{R}^n$, která je definována pomocí konečně mnoha LMI, se nazývá **spektraedr**. Tedy:

$$S = \left\{ (x_1, \dots, x_m) \in \mathbb{R}^m \mid A_0 + \sum_{i=1}^m A_i x_i \succeq 0 \right\}$$

pro nějaké symetrické matice $A_0, \dots, A_m \in S^n$.

Můžeme si všimnout analogie s definicí polyedru, který je přípustnou množinou pro lineární program. Podobně spektraedr je přípustnou množinou pro semidefinitní program.

Geometricky je spektraedr definován jako průnik pozitivně semidefinitního kuželu S_+^n a afinního podprostoru $\text{span}\{A_1, \dots, A_m\}$ posunutého do A_0 .

Spektraedry jsou uzavřené množiny, neboť LMI je ekvivalentní nekonečně mnoha skalárním nerovnostem ve tvaru $v^T(A_0 + \sum_{i=1}^m A_i x_i)v \geq 0$, jednu pro každou hodnotu $v \in \mathbb{R}^n$.

Vždy můžeme několik LMI „scucnout“ do jedné. Stačí zvolit matice A_i blokově diagonální. Odtud snadno víme, že polyedr je speciálním případem spektraedru. Polyedr bude mít všechny matice A_i diagonální.

Příklad.

$$\left\{ (x, y) \in \mathbb{R}^2 \mid A(x, y) = \begin{bmatrix} x+1 & 0 & y \\ 0 & 2 & -x-1 \\ y & -x-1 & 2 \end{bmatrix} \succeq 0 \right\}$$

4.2 Primární úloha

Semidefinitní program je lineární optimalizační problém přes spektraedr. Primární úlohu ve standardním tvaru můžeme napsat jako:

$$\inf \{ \langle C, X \rangle \mid \langle A_i, X \rangle = b_i, i = 1, \dots, m; X \succeq 0 \}, \quad (\text{SDP-P})$$

kde $C, A_i \in S^n$, $\langle X, Y \rangle = \text{Tr}(X^T Y) = \sum_{ij} X_{ij} Y_{ij}$ a $X \in S^n$ je proměnná, nad kterou provádíme minimalizaci.

Příklad.

$$\inf \left\{ \left\langle \begin{bmatrix} 2 & 1 \\ 1 & 0 \end{bmatrix}, \begin{bmatrix} x_{11} & x_{12} \\ x_{12} & x_{22} \end{bmatrix} \right\rangle \mid \left\langle \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}, \begin{bmatrix} x_{11} & x_{12} \\ x_{12} & x_{22} \end{bmatrix} \right\rangle = 1, \begin{bmatrix} x_{11} & x_{12} \\ x_{12} & x_{22} \end{bmatrix} \succeq 0 \right\} \quad (\text{P3})$$

Po úpravě:

$$\inf \left\{ 2x_{11} + 2x_{12} \mid x_{11} + x_{22} = 1, \begin{bmatrix} x_{11} & x_{12} \\ x_{12} & x_{22} \end{bmatrix} \succeq 0 \right\}.$$

Jak vypadá přípustná množina? Použijeme Sylvesterovo kritérium, tj.

$$x_{11} \geq 0, x_{11}x_{22} - x_{12}^2 \geq 0.$$

Z LMI vyjádříme x_{22} , tj.

$$x_{22} = 1 - x_{11}$$

Dosadíme do přechozího a dostaneme

$$x_{11} \geq 0, x_{11}(1 - x_{11}) - x_{12}^2 \geq 0$$


Po úpravě

$$x_{11} \geq 0, \left(x_{11} - \frac{1}{2}\right)^2 + x_{12}^2 \leq \frac{1}{4}$$

Vidíme tedy, že přípustná množina (zobrazena na obrázku 4.1) je kruh s poloměrem $\frac{1}{2}$ a se středem v bodě $(x_{11}, x_{12}) = (\frac{1}{2}, 0)$. Řešením úlohy je matice

$$X^* \approx \begin{bmatrix} 0.1464 & -0.3536 \\ -0.3536 & 0.8536 \end{bmatrix}$$

s cenou ≈ -0.4142 . Implementace v softwaru MOSEK: <https://github.com/c0n73x7/D1PL0MK4/blob/master/mosek/ex3.py>.



Obrázek 4.1: Přípustná množina řešení k úloze P3.

4.3 Dualita

Duální úloha

Podobně jako u lineárního programování použijeme Lagrangeovu dualitu k odvození duální úlohy k úloze SDP-P. Lagrangeova funkce je ve tvaru:

$$L(X, \lambda, Z) = \langle C, X \rangle - \sum_{i=1}^m \lambda_i (\langle A_i, X \rangle - b_i) - \langle Z, X \rangle.$$

K ní duální funkce:

$$d(\lambda, Z) = \inf_{X \in S^n} L(X, \lambda, Z) = \begin{cases} \lambda^T b & \dots \ C - \sum_{i=1}^m \lambda_i A_i - Z = 0, \\ -\infty & \dots \text{jinak.} \end{cases}$$

Duální funkci použijeme v duální úloze:

$$\sup \left\{ \lambda^T b \mid C - \sum_{i=1}^m \lambda_i A_i \succeq 0 \right\}, \quad (\text{SDP-D})$$

kde $\lambda = (\lambda_1, \dots, \lambda_m)$ je duální proměnná.

Dostali jsme duální úlohu SDP-D k úloze SDP-P.

Slabá dualita semidefinitního programování

Vztah mezi primární a duální úlohou je stejně jako u lineárního programování takový, že řešení jedné úlohy lze použít jako odhad na úlohu druhou. Necht' X je libovolné přípustné řešení primární úlohy a y je libovolné přípustné řešení duální úlohy. Potom

$$\langle C, X \rangle - b^T y = \langle C, X \rangle - \sum_{i=1}^m y_i \langle A_i, X \rangle = \left\langle C - \sum_{i=1}^m A_i y_i, X \right\rangle \geq 0. \quad (4.2)$$

Za pozornost stojí poslední nerovnost, která plyne z toho, že skalární součin dvou pozitivně semidefinitních matic je nezáporný. Odvození je následující: mějme dvě matice $S, T \succeq 0$. Matici S můžeme napsat jako součet „rank one“ matic. Označme $r_S = \text{rank}(S)$, tj.

$$S = \sum_{i=1}^{r_S} \lambda_i s_i s_i^T,$$

kde s_i je i -tý sloupeček matice S . Dále se podíváme na součin $T \cdot S_i$. Tedy pro $i = 1, \dots, r_S$ platí

$$T \cdot S_i = \lambda_i s_i^T T s_i \geq 0,$$

kde nerovnost plyne z toho, že matice T je pozitivně semidefinitní.

O nerovnosti 4.2 se mluví jako o slabé dualitě semidefinitního programování.

Silná dualita semidefinitního programování

Věta 11 (podmínka optimality). *Nechť X je přípustné řešení úlohy SDP-P a y je přípustné řešení úlohy SDP-D taková, že splňují podmínku (komplementární skluzovosti)*

$$\left(C - \sum_{i=1}^m A_i y_i \right) X = 0.$$

Potom X je optimální řešení úlohy SDP-P a y je optimální řešení úlohy SDP-D.

Obracená implikace sama o sobě neplatí, což znamená, že obecně dualitní rozdíl u semidefinitního programování není nulový. Musíme přidat podmínku kvalifikace omezení, kterou je například již zmíněná Slaterova podmínka. Ta je pro úlohu SDP-P ve tvaru $X \succ 0$ a pro úlohu SDP-D ve tvaru $C - \sum_i A_i y_i \succ 0$.

Věta 12 (silná dualita semidefinitního programování). *Nechť úloha SDP-P a úloha SDP-D jsou striktně přípustné. Potom dualitní rozdíl jejich optimálních řešení je nulový.*

BACKLOG

Stopa matice $A \in R^{n \times n}$ je $\text{Tr}(A) = \sum_{i=1}^n A_{ii}$.

Věta 13. S, T jsou pozitivně definitní $\implies S + T$ je pozitivně definitní

Důkaz. $x^T(S + T)x = x^T S x + x^T T x > 0$ □

Úlohy s racionálními daty nemusí mít racionální optimální řešení. příklad
Jen 3 kužely s vlastnostmi jako PSD cone. Zmrzlina, a ještě jeden. Vnitřek S_+^n je S_{++}^n .

Fejérová věta

Kapitola 5

Kombinatorická optimalizace

5.1 Celočíselné lineární programování

složitost úlohy, relaxace, výčet algoritmů, aproximace, ...

5.2 Celočíselné semidefinitní programování

složitost úlohy, relaxace, výčet algoritmů, aproximace, ...

Část II

Kombinatorické úlohy

Kapitola 6

Shannonova kapacita

Představme si zašuměný komunikační kanál, kterým posíláme zprávy, které jsou složeny ze symbolů (písmen) nějaké konečné abecedy. Vlivem šumu mohou být některé symboly špatně interpretovány a naším cílem je vybrat co největší počet slov délky k tak, aby žádná dvě slova nebyla vlivem šumu zaměnitelná.

Problém si formalizujeme v řeči teorie grafů. Mějme neorientovaný graf $G = (V, E)$, kde množina vrcholů představuje symboly z konečné abecedy a dva vrcholy x, y jsou spojeny hranou, pokud vrchol x může být vlivem šumu zaměněn za y .

Maximální počet nezaměnitelných zpráv délky 1 je roven $\alpha(G)$, kde $\alpha(G)$ značí velikost největší nezávislé množiny v grafu G . Pro popis delších zpráv definujeme **silný součin** $G \cdot H$ grafů G a H následovně:


$$V(G \cdot H) = V(G) \times V(H),$$

$$\begin{aligned} E(G \cdot H) = & \{(i, u)(j, v) \mid ij \in E(G) \wedge uv \in E(H)\} \cup \\ & \{(i, u)(j, v) \mid ij \in E(G) \wedge u = v\} \cup \\ & \{(i, u)(j, v) \mid i = j \wedge uv \in E(H)\}. \end{aligned}$$

Příklad. Pro graf $P_4 = a - b - c - d - e$ je silný součin $P_4 \cdot P_4$ zobrazen na obrázku 6.1. Z obrázku je hezky vidět, že např. zpráva cd (na obrázku červeně) může být zaměněna s bc , bd , be , cc , ce , dc , dd a de (na obrázku oranžově). Podobně pro další zprávy.

Pro jednoduchost budeme silný součin k kopií grafu G značit G^k . Tedy $\alpha(G^k)$ je maximální počet nezaměnitelných zpráv délky k . **Shannonova kapacita** grafu G je definována jako

$$\Theta(G) = \sup \{ \alpha(G^k)^{1/k} \mid k = 1, 2, \dots \}.$$

Obrázek 6.1: $P_4 \cdot P_4$

Neví se, zda pro libovolný graf G existuje vůbec nějaký algoritmus, kterým bychom určili hodnotu $\Theta(G)$. Přesto je alespoň něco známo. Pro perfektní grafy Claude E. Shannon ukázal, že $\Theta(G) = \alpha(G)$. To také znamená, že pro perfektní grafy lze $\Theta(G)$ určit v polynomiálním čase. Dalším kdo se problémem zabýval byl László Lovász, který velmi hezkým způsobem ukázal, že kružnice délky 5 má kapacitu $\sqrt{5}$. Na Lovászův postup se dále podíváme, protože vede k obecnému hornímu odhadu na $\Theta(G)$.

6.1 $\Theta(C_5) = \sqrt{5}$

Tenzorový součin vektorů $\mathbf{u} = (u_1, \dots, u_n)$ a $\mathbf{v} = (v_1, \dots, v_m)$ je

$$\mathbf{u} \circ \mathbf{v} = (u_1 v_1, \dots, u_1 v_m, u_2 v_1, \dots, u_n v_m).$$

Užitečné bude následující pozorování, které dává do souvislosti skalární a tenzorový součin.

Pozorování. *Nechť \mathbf{x}, \mathbf{u} jsou vektory délky n a \mathbf{y}, \mathbf{v} jsou vektory délky m . Potom platí*

$$(\mathbf{x} \circ \mathbf{y})^T (\mathbf{u} \circ \mathbf{v}) = (\mathbf{x}^T \mathbf{u}) (\mathbf{y}^T \mathbf{v}). \quad (6.1)$$

Důkaz. Levá strana:

$$\begin{aligned} & (x_1 y_1, x_1 y_2, \dots, x_1 y_m, \dots, x_n y_m)^T (u_1 v_1, u_1 v_2, \dots, u_1 v_m, \dots, u_n v_m) = \\ & x_1 y_1 u_1 v_1 + x_1 y_2 u_1 v_2 + \dots + x_1 y_m u_1 v_m + \dots + x_n y_m u_n v_m \end{aligned}$$

Pravá strana:

$$(x_1 u_1 + \cdots + x_n u_n) \cdot (y_1 v_1 + \cdots + y_m v_m) = \\ x_1 y_1 u_1 v_1 + x_1 y_2 u_1 v_2 + \cdots + x_1 y_m u_1 v_m + \cdots + x_m y_m u_n v_m$$

□


Mějme graf $G = (V, E)$, kde $V = \{1, \dots, n\}$. Systém $(\mathbf{v}_1, \dots, \mathbf{v}_n)$ jednotkových vektorů v Euklidovském prostoru takový, že

$$\forall ij \notin E \implies \mathbf{v}_i \perp \mathbf{v}_j$$

nazýváme **ortonormální reprezentace** grafu G . Poznamenejme, že každý graf má nějakou ortonormální reprezentaci, např. $1 \mapsto \mathbf{e}_1, \dots, n \mapsto \mathbf{e}_n$.

Lemma 5. *Nechť $(\mathbf{u}_1, \dots, \mathbf{u}_n)$ je ortonormální reprezentace grafu G a $(\mathbf{v}_1, \dots, \mathbf{v}_m)$ je ortonormální reprezentace grafu H . Potom $\mathbf{u}_i \circ \mathbf{v}_j$ je ortonormální reprezentace grafu $G \cdot H$.*

Důkaz. Použijeme vztah 6.1. $(u_i \circ v_j)^T (u_k \circ v_l) = (u_i^T u_k) (v_j^T v_l) = 0 \iff ik \notin E(G) \vee jl \notin E(H)$. □



Obrázek 6.2: Ortonormální reprezentace $G \cdot H$.

Hodnotu ortonormální reprezentace (u_1, \dots, u_n) definujeme jako:

$$\min_c \max_{i=1, \dots, n} \frac{1}{(c^T u_i)^2}.$$

Vektoru c , pro který nastává minimum říkáme **handle** dané ortonormální reprezentace.

Dále definujeme funkci $\vartheta(G)$ jako minimální hodnotu přes všechny ortonormální reprezentace grafu G . Ortonormální reprezentaci, pro kterou nastává minimum nazýváme **optimální**.

Funkci $\vartheta(G)$ se říká **Lovászova theta funkce** a ona je právě již zmíněným horním odhadem na $\Theta(G)$. Podívejme se na některé její vlastnosti.

Lemma 6. $\vartheta(G \cdot H) \leq \vartheta(G)\vartheta(H)$

Důkaz. Necht' (u_1, \dots, u_n) je optimální ortonormální reprezentace grafu G s „rukojetí“ c a (v_1, \dots, v_m) je optimální ortonormální reprezentace grafu H s „rukojetí“ d . Pak $c \circ d$ je jednotkový vektor a platí:

$$\vartheta(G \cdot H) \leq \max_{i,j} \frac{1}{\left((c \circ d)^T (u_i \circ v_j)\right)^2} = \max_i \frac{1}{(c^T u_i)^2} \cdot \max_j \frac{1}{(d^T v_j)^2} = \vartheta(G)\vartheta(H).$$

□

Lemma 7. $\alpha(G) \leq \vartheta(G)$

Důkaz. TODO (máš to někde na papíře)

□

Lemma 8. $\Theta(G) \leq \vartheta(G)$

Důkaz. TODO (máš to někde na papíře)

□

Věta 14. $\Theta(C_5) = \sqrt{5}$

Důkaz. TODO (obě nerovnosti, obrázek, spherical cosine theorem)

□

6.2 Další vlastnosti $\vartheta(G)$

vztah k barvení (\overline{G}) , ...

6.3 Semidefinitní program pro $\vartheta(G)$

formulace semidefinitních programů (jsou dva ekvivalentní – to asi nenaimplementuješ, je to docela pekelný, nic nespočítáš), subgradientní aproximační metoda (zkusit naimplementovat???)

Kapitola 7

Problém maximálního řezu

7.1 Kvadratické programování

kvadratický program, striktní kvadratický program

7.2 Relaxace a vektorové programování

ekvivalence se semidefinitním programováním

TODO

formulace úlohy, aproximační algoritmy, porovnání semidefinitních programů,
... komplexní semidefinitní programování, ...

Kapitola 8

Problém obchodního cestujícího

Závěr